

# Regressão Polinomial

Inteligência Artificial I

Prof. Ricardo A. Manfredini

[ricardo.manfredini@farroupilha.ifrs.edu.br](mailto:ricardo.manfredini@farroupilha.ifrs.edu.br)



# Agenda da Apresentação

- **Revisão Rápida:** O que é Regressão?
- **O Problema:** As Limitações da Regressão Linear.
- **A Solução:** Introdução à Regressão Polinomial.
- **Como Funciona?** A Matemática por Trás do Modelo.
- **Visualizando o Poder:** Graus do Polinômio.
- **O Grande Desafio:** Cuidado com o *Overfitting*.
- **A Pergunta de Ouro:** Como Escolher o Grau Certo?
- **Vantagens vs. Desvantagens.**
- **Conclusão e Próximos Passos.**




# O que é Regressão?

O objetivo da análise de regressão é **modelar a relação** entre uma variável dependente (o que queremos prever) e uma ou mais variáveis independentes (nossos dados).

## Exemplo Clássico: Regressão Linear

- Tenta encontrar a **melhor linha reta** que se ajusta aos dados.
- Simples, rápido e muito interpretável.

# Modelo de Regressão Linear com Excelente Ajuste




# O Problema: As Limitações da Regressão Linear

O mundo real raramente é perfeitamente linear. Muitos fenômenos seguem padrões curvos.

**O que acontece quando tentamos forçar uma linha reta em dados curvos?**

- O modelo não consegue capturar a tendência real.
- As previsões serão imprecisas.
- Isso é chamado de **Underfitting** (Sub-ajuste)

# Modelo de Regressão Linear com Desempenho Insatisfatório



# Solução: Introdução à Regressão Polinomial

A Regressão Polinomial nos permite modelar essas relações não-lineares, ajustando uma **linha curva** aos dados.

**Definição:** É um tipo de regressão onde a relação entre a variável independente  $x$  e a dependente  $y$  é modelada como um polinômio de grau  $n$ .

Apesar do nome e da curva, ela é considerada um caso especial de **Regressão Linear Múltipla**. Vamos ver o porquê!

# Como Funciona? A Matemática por Trás

A "mágica" está na **engenharia de features**. Nós criamos novas features a partir das existentes.

Regressão Polinomial Simples:

$$y = \beta_0 + \beta_1 x_1$$

- $y$ : Variável dependente (o valor que queremos prever ou explicar).
- $x_1$ : Variável independente (a variável usada para explicar ou prever  $y$ ).
- $\beta_0$ : Intercepto (valor de  $y$  quando  $x_1 = 0$ ).
- $\beta_1$ : Coeficiente angular (mudança em  $y$  para um aumento de uma unidade em  $x_1$ ).



# Como Funciona? A Matemática por Trás

A "mágica" está na **engenharia de features**. Nós criamos novas features a partir das existentes.

Regressão Polinomial (Grau 2):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2$$

- Nós criamos uma nova feature ( $x_1^2$ ).
- O modelo ainda é **linear em relação aos coeficientes** ( $\beta_0, \beta_1, \beta_2$ ), e é isso que importa para o algoritmo.




# Visualizando o Poder: Graus do Polinômio

O **grau do polinômio** determina a complexidade e a flexibilidade da curva.

**Grau 1 (Linear):** Uma linha reta. Não captura a tendência.

**Grau 2 (Quadrático):** Uma parábola simples. Parece um bom ajuste!

**Grau 4:** Uma curva mais complexa, que se ajusta ainda mais aos pontos.



# O Grande Desafio: Cuidado com o *Overfitting*


E se usarmos um grau muito alto? Por exemplo, grau 20?

O modelo pode se tornar **flexível demais**. Ele começará a memorizar os dados de treino, incluindo o ruído, em vez de aprender a tendência geral.

## Isso é **Overfitting (Sobre-ajuste)**:

- O modelo tem um desempenho excelente nos dados de treino.
- O modelo tem um desempenho péssimo em dados novos e nunca vistos.

# O Grande Desafio: Cuidado com o *Overfitting*




# A Pergunta de Ouro: Como Escolher o Grau Certo?

O **objetivo** é encontrar o equilíbrio: um modelo complexo o suficiente para capturar a tendência, mas simples o suficiente para generalizar para novos dados. (Viés vs. Variância)

## Técnicas Comuns:

1. **Visualização:** Plotar os dados pode dar uma intuição inicial.
2. **Métricas de Avaliação:** Use um conjunto de teste ou validação. Monitore o erro (ex: Erro Quadrático Médio - MSE). O erro de treino sempre diminui com o aumento do grau, mas o erro de teste começará a aumentar no ponto de overfitting.
3. **Validação Cruzada (Cross-Validation):** A abordagem mais robusta para encontrar o grau que melhor generaliza.

**Métricas de Avaliação:** Use um conjunto de teste ou validação. Monitore o erro (ex: Erro Quadrático Médio - MSE). O erro de treino sempre diminui com o aumento do grau, mas o erro de teste começará a aumentar no ponto de overfitting.



# Vantagens vs. Desvantagens

## Vantagens:

- **Flexibilidade:** Pode modelar uma vasta gama de relações não-lineares.
- **Simplicidade Relativa:** Baseado nos conceitos da regressão linear, o que o torna mais fácil de entender do que modelos mais complexos.

## Desvantagens:

- **Risco de Overfitting:** A principal preocupação. Requer cuidado na escolha do grau.
- **Extrapolação Perigosa:** O comportamento do modelo fora do intervalo dos dados de treino é imprevisível e geralmente ruim.
- **Interpretabilidade:** Mais difícil de interpretar do que um modelo linear simples.

# Conclusão

- A Regressão Polinomial é uma ferramenta **essencial e poderosa** no arsenal de um cientista de dados para lidar com dados não-lineares.
- O segredo do sucesso é gerenciar o **trade-off entre viés e variância** para evitar o overfitting.
- Sempre valide seu modelo em um conjunto de dados separado!



# Perguntas...



**INSTITUTO FEDERAL**  
Rio Grande do Sul  
Campus Farroupilha